Apuntes clase 2

Repaso clase 1

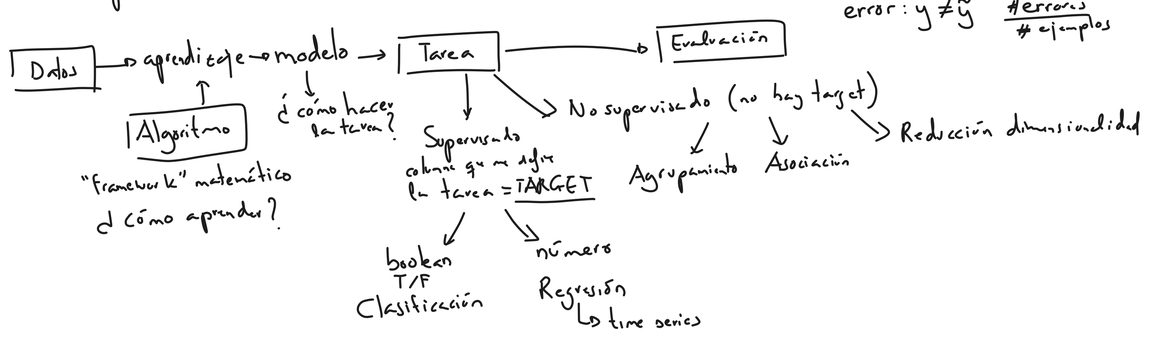

* avance métricas:

clasificación
% errores
error: $y \neq \tilde{y}$

y: target real
$\tilde{y}$: predicción modelo
$\frac{\#\text{errores}}{\#\text{ejemplos}}$

Workflow ML

(Business Understanding) →

Data Understanding
- distribución columnas (predictores: X) → Data preparation
- relación predictores (X) y target (y)

INP! avg (target) = 21%

Data Preparation
"traducir" todo a numérico →
- categóricas
- nulos

Modelling
- escoger algoritmo →
- parámetros: fine-tunning

Evaluación
- métricas
- monitorización

Overfitting

y: target
€ colchón

X: predictor
anchura m

x: datos/filas
x: datos nuevos

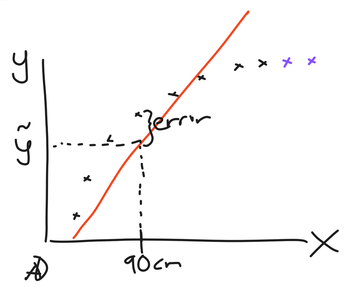

Algoritmo: $Y = \beta_0 + \beta_1 X$

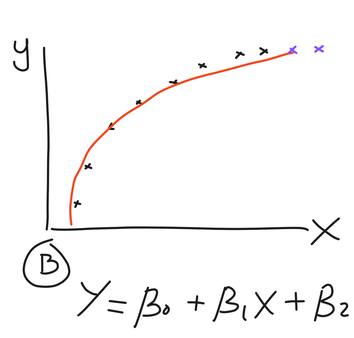

$Y = \beta_0 + \beta_1 X + \beta_2 X^2$

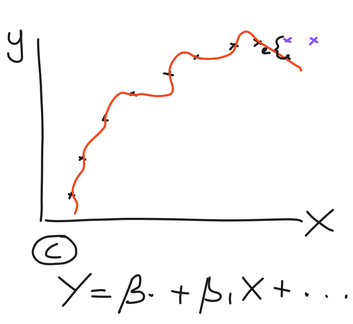

$Y = \beta_0 + \beta_1 X + \ldots + \beta_n X^n$

Métrica: $error = |y - \tilde{y}|$

error grande
(=)
error grande.

error pequeño
(=)
error pequeño

error 0
(≠)
error grande

Métrica (datos nuevos)

Objetivo: métricas en datos nuevos y en datos vistos deben ser parecidas

Data preparation

Nulos

1. No eliminar fila, porque cambia la distribución datasets

excepciones:

I. Nulo en el target
II. Afecta MUY pocas filas < 0,5 %
III. Fila con nulos en muchos predictores

2. Si el predictor > 90-95% nulos → eliminar columnas

Tratamiento

I. Según numérica/categórica
II. Según algoritmos

Técnicas

prio 3:
- mediana/media (num), moda (cat.)

prio 2:
- valor distinto (cat.), fuera de rango (núm.) de un subgrupo
  - Apunte: según algoritmo
  - → funcionan bien métodos de reglas
  - → funcionan mal: geométricos vecindad
- valores cercanos:
  - → time series: día anterior
  - → ML: vecindad K-NN

prio 1:
- otras variables
- data eng.

Tratamiento categóricas

Previo: ajuste de tipos → Python puede leer mal una variable (IDs)

¿es booleano? (2 etiquetas (nulo/no nulo))
- sí: True/False o 1/0
- >2 etiq: no: ¿tiene orden?
  - 1. Intrínseco: Label Encoding
    - → respuestas encuesta
      Muy a favor ⟷ Muy en contra
      0 1 2 3 4 5
    - → versiones app

Android: 'Baklava'	16	1
'VanillaIce'	13	2
⋮		3

    ¿tiempo?
    - no ← ¿<100 etiq.? ← no ← reducir # etiquetas: agrupar minoritarias
      - sí: One Hot Encoding
      - no: Frecuency Encoding

id	ciudad	conteo etiq.
1	BCN	BCN = 2
2	MAD	MAD = 3
3	BCN	
4	MAD	
5	MAD	

⇓

id	ciudad_FE
1	2
2	3
3	2
4	3
5	3

  - sí → 2. Fuentes externas
    - ciudad: PIB/cap
    - aeropuerto: # pasajeros anuales
    - matrícula: antigüedad