

End-to-end ML



Annex III
Métodos de rebalanceo

Datasets desbalanceados



} **A partir de <20% puede haber problemas.
Se notan más cuanto menos registros tenemos.**

Por ejemplo, es peor tener 5k registros de la clase minoritaria y que representen un 20% del dataset total que tener 50k registros de la clase minoritaria que representen un 15% del dataset total.

Nuestro objetivo no es llegar al 50%-50% sino a un balance que solucione lo suficiente el problema.



Detección del problema

minoritaria

mayoritaria


En clasificación:

Mi modelo predice menos ejemplos de los que realmente existen (recall muy baja en caso que la clase minoritaria sean los 1)


En regresión:

Mi modelo no es capaz de predecir valores de la distribución que aparecen poco.
Por ejemplo, en un target sesgado a la izquierda, casi nunca detecta valores altos


Técnicas de oversampling




Random Oversampling




SMOTE




SMOTE




SMOTE



Técnicas de undersampling




Random undersampling



Tomek Links

● Filas reales de la clase minoritaria

● Filas reales de la clase mayoritaria



Eliminar el mayoritario de pares parecidos