



APRENDIZAJE SUPERVISADO

Alejandro Tinto





Presentación



Alejandro Tinto

Business Intelligence Engineer II en Amazon



- Ciencias Empresariales- Management Universidad Pompeu Fabra.
- Master de Data Science en Nuclio Digital School.
- Process Control Specialist en Amazon Barcelona
- Business Intelligence Engineer en Amazon Luxemburgo





IA -> ML -> DL -> GenAI


Deep learning es una parte de la IA





IA -> ML -> DL -> GenAI

GenAI es una parte del deep learning





1. Regresión en Machine Learning

Los algoritmos de regresión son modelos de machine learning supervisado que se utilizan para predecir un valor numérico continuo.

La idea es encontrar la relación matemática entre las variables independientes (features) y la variable dependiente (target), minimizando el error entre las predicciones del modelo y los valores reales


- Overfitting
- Underfitting

Existen diferentes algoritmos, y cuando hay la variable de temporalidad hablamos de series temporales.



2. Repaso - ESTRATEGIAS DE VALIDACIÓN: RANDOM HOLDOUT

Se considera que un modelo de Machine Learning es preciso cuando mediante el mismo obtenemos buenas métricas de evaluación en los conjuntos de test y validación.



La selección de la estrategia de validación es uno de los puntos más importantes en el desarrollo de modelos de Machine Learning, y es importante ajustarla a las características del problema concreto que estamos intentando resolver. En ese sentido, el tamaño de las particiones debe ajustarse al tamaño del dataset, de manera que la partición de entrenamiento sea suficiente para ajustar el modelo y las particiones de validación sean suficientemente grandes para obtener métricas de evaluación estadísticamente significativas.

Durante el curso revisaremos métodos avanzados de validación como k-fold o bootstrap orientados a lidiar con este tipo de problemas.



03. OUTLIERS Y NORMALIZACIÓN

OUTLIERS

Ciertos algoritmos son sensibles a outliers.

Sensibles porque significa que la presencia o no de este tipo de datos puede influenciar enormemente el aprendizaje del algoritmo y llevar a predicciones que no se ajusten a la realidad.

Familia	Algoritmo	Sensibilidad
Métodos geométricos	- Regresión lineal - Regresión logística	Si
Métodos de reglas	- Decision Tree - Random Forest - XGBoost	No
Métodos de vecindad	- K-NN - K-Means	Si
Métodos probabilísticos	Naïve Bayes	No

CORRECCIÓN DE OUTLIERS

Los modelos de la familia de **métodos de reglas y de vecindad son sensibles a los outliers**.

Existen diversos métodos para ajustar y corregir los outliers:

1. Eliminación de registros:

- reconocemos el outlier como un error **random**
- El número de filas afectadas es relativamente pequeño (<1% of the total dataset)

2. Transformación

3. Logaritmica:

- Contrae los valores extremos, trayendo los outliers más cerca del grueso de la distribución
- Aplicando la misma transformación también al target nos aseguramos una relación lineal entre ellas (necesario para la Regresión lineal)


2. Scaling (en non-supervised methods)

- Normalizar
- Escala 0-1

3. Imputación: al igual que con los valores nulos, podemos aplicar las mismas técnicas a los outliers

5 LA DISTRIBUCIÓN NORMAL: INTRODUCCIÓN

Nos referimos a una distribución de probabilidad como la función que nos permite mapear a cada posible valor de una variable (eje de abscisas) su probabilidad de ocurrencia. La distribución normal o de Gauss es la distribución de probabilidad de variable continua más frecuente, y aparece frecuentemente en estadística y Machine Learning, pues permite modelar diversos fenómenos tanto naturales como artificiales. La distribución normal queda caracterizada por dos valores: la media y la desviación tipo.



- **Media o promedio:** número que representa la esperanza (valor esperado) de la distribución, obtenido sumando todos los valores y dividiendo entre el número total de elementos de la muestra. Para la distribución normal coincide con la mediana.

$$\mu = \frac{1}{N} \sum_{i=1}^N x_i$$

- **Desviación estandar:** número que representa la dispersión de la distribución, obtenido promediando la desviación de los datos respecto a la media. Al cuadrado de la desviación tipo se le denomina varianza.

$$\sigma = \sqrt{\frac{\sum_{i=1}^N (x_i - \mu)^2}{N}} \quad s = \sqrt{\frac{\sum_{i=1}^N (x_i - \bar{x})^2}{N - 1}}$$



5

LA DISTRIBUCIÓN NORMAL: INTERVALOS DE CONFIANZA

$$\mu \pm \sigma$$


- Incluirán el 68% de los datos

$$\mu \pm 2\sigma$$

- Incluirán el 95% de los datos

$$\mu \pm 3\sigma$$

- Incluirán prácticamente todas las observaciones.




5 LA DISTRIBUCIÓN NORMAL: OUTLIERS

La distribución normal se utiliza frecuentemente para detectar valores atípicos (outliers), mediante los intervalos de confianza del 95 o el 99%. No es el único método para la detección de éstos, y también puede utilizarse la regla del 1,5IQR (media y 1,5 veces la diferencia entre los cuartiles 1 y 3).


Mediante la desviación tipo

- **Upper bound:** $\mu + 3\sigma$
- **Lower bound:** $\mu - 3\sigma$



Mediante el rango intercuartílico

- **Upper bound:** $Q3 + 1,5IQR$
- **Lower bound:** $Q1 - 1,5IQR$







5

LA DISTRIBUCIÓN NORMAL: DISTRIBUCIONES NO NORMALES

Un error común es inferir propiedades de la distribución normal cuando la distribución de la variables es claramente no normal. Para solventarlo, existen diversos métodos que nos permiten transformar la distribución original, como la utilización de escalas alternativas (transformación logarítmica, por ejemplo). Esto es útil, por ejemplo, cuando tenemos variables con una gran acumulación de datos alrededor del 0, y menos casos en valores elevados.



Transformaciones para outliers

1. **Scaling:** Se aplica principalmente en algoritmos sensibles a la magnitud de las variables y a las distancias entre los datos, como **K-Nearest Neighbors (KNN)**, **SVM**.... El escalado garantiza que todas las variables contribuyan de forma equilibrada, evitando que aquellas con rangos numéricos mayores dominen el comportamiento del modelo.
2. **Transformación logarítmica:** Es útil cuando existen **outliers positivos o distribuciones asimétricas**. Al aplicar un logaritmo, se reduce el impacto de valores extremos y se aproxima la variable a una distribución más normal. Esto beneficia a modelos como **regresión lineal**, **árboles de decisión** y otros algoritmos que no se basan directamente en distancias.

TRANSFORMACIÓN LOGARÍTMICA (base 10)

Utilizaremos la siguiente función matemática.

- X es la variable con outliers que queremos transformar.
- Y es la variable transformada que utilizaremos en su lugar.

$$\text{Log}_{10}(x) = y$$

equivale a

$$10^y = X$$

A que valor debo elevar el 10 para que me de 1 ?

10 elevado a 0 (y) es 1 (x)

A que valor debo elevar el 10 para que me de 10 ?

10 elevado a 1 es 10

A que valor debo elevar el 10 para que me de 100 ?

10 elevado a 2 es 100

A que valor debo elevar el 10 para que me de 1000 ?


10 elevado a 3 es 1000

A que valor (y) debo elevar el 10 para que me de X?

NOTA: si X es igual a 0, el $\log_{10}(0)$ no existe, por esta razón aplicaremos la transformación $\log_{10}(1+x)$

TRANSFORMACIÓN LOGARÍTMICA (base 10)

El efecto de la transformación es el siguiente:



- Los valores extremos se agrupan en el centro de la distribución
- La distribución resultante es parecida a una distribución normal (aunque no exacta)

TRANSFORMACIÓN LOGARÍTMICA (base 10)

En resumen la transformación logarítmica nos ofrece las siguientes ventajas:

1. Transformación de la distribución en una distribución normal (para distribuciones sesgadas)

Lo que permite utilizar ciertas técnicas como el BoxPlot para detectar outliers

2. Eliminación de outliers ya que los trae más al centro de la distribución

Lo que permite utilizar ciertos algoritmos como la Regresión lineal con mayor tranquilidad

3. Comparación de distribuciones en el Data Understanding utilizando técnicas de correlación lineal

Lo que facilita el proceso de análisis cuando tenemos muchas variables

NOTA: la transformación logarítmica dificulta la lectura de resultados y la explicación del modelo resultante




6 CORRELACIÓN LINEAL ENTRE VARIABLES: BASICS

La correlación lineal o de Pearson entre dos variables se define como una medida de la fuerza y sentido de la relación lineal entre dos variables. Se considera que dos variables cuantitativas están correlacionadas cuando los valores de una de ellas varían sistemáticamente con respecto a los valores homónimos de la otra: si tenemos dos variables (A y B) existe correlación entre ellas si al disminuir los valores de A lo hacen también los de B y viceversa. Geométricamente, puede interpretarse como el coseno del ángulo que forman las variables una vez centradas. El coeficiente de correlación de Pearson toma valores de -1 a 1, reservándose el valor 0 para la ausencia de correlación lineal, tal y como se muestra en los ejemplos inferiores.

$$r = \frac{\sigma_{xy}}{\sigma_x \sigma_y}$$

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$






6

CORRELACIÓN LINEAL ENTRE VARIABLES: RELACIONES NO LINEALES

Es importante notar que el coeficiente de correlación lineal sólo mide la relación lineal entre variables, y no otros tipos de relación. En estos casos, es posible trabajar transformaciones sobre éstas que nos permitan ajustar la escala de una o ambas variables para linearizar su relación, o utilizar alternativas al coeficiente de correlación de Pearson como el coeficiente de correlación de Spearman.





CORRELACIÓN y causalidad

La correlación no implica causalidad: el hecho de que dos variables estén asociadas no significa que una cause a la otra. Esta confusión puede llevar a interpretaciones erróneas, ya que la relación observada puede deberse a coincidencias, a la influencia de un tercer factor, o a una relación bidireccional.



Confundir correlación con causalidad constituye una falacia lógica conocida como *cum hoc ergo propter hoc*, donde se asume erróneamente que el hecho de que dos eventos ocurran juntos significa que uno provoca al otro

Es fundamental utilizar métodos adecuados para demostrar causalidad. La correlación solo indica que existe una relación, pero no explica el mecanismo ni garantiza que una variable sea responsable de los cambios en la otra.



6

CORRELACIÓN NO IMPLICA CAUSALIDAD






6

CORRELACIÓN NO IMPLICA CAUSALIDAD

Popularity of the first name Thomas

correlates with

Motor vehicle thefts in Maine



--- Babies of all sexes born in the US named Thomas · Source: US Social Security Administration


— The motor vehicle theft rate per 100,000 residents in Maine · Source: FBI Criminal Justice Information Services

1985-2022, $r=0.979$, $r^2=0.959$, $p<0.01$ · tylervigen.com/spurious/correlation/1882

Bachelor's degrees awarded in Philosophy

correlates with

Electricity generation in Yemen



--- Bachelor's degrees conferred by postsecondary institutions, in field of study: Philosophy and religious studies · Source: National Center for Education Statistics

— Total electricity generation in Yemen in billion kWh · Source: Energy Information Administration

2012-2021, $r=0.968$, $r^2=0.936$, $p<0.01$ · tylervigen.com/spurious/correlation/1431

Aclaratoria: transformación

Transformaciones de Datos: Log vs Min-Max

Log Transform

- Comprime valores grandes (reduce outliers).
- Convierte distribuciones sesgadas → más simétricas.
- Útil en: datos exponenciales, ingresos, conteos.
- Modelos: regresión lineal/logística, modelos lineales en general.

Min-Max Scaling

- Reescala valores a $[0,1]$.
- No cambia la forma de la distribución.
- Útil en: cuando el algoritmo es sensible a escala.
- Modelos: redes neuronales, kNN, SVM, clustering (K-means).



07. MODELOS LINEALES

7 MODELOS LINEALES: BASICS

Los modelos lineales, al igual que el coeficiente de correlación, buscan cuantificar la correlación lineal entre dos variables, pero en lugar de tratarlas de forma simétrica hacemos una distinción entre ambas. En consecuencia, los objetivos que pueden resolverse con un análisis de correlación y un análisis de regresión son distintos.


Variables Independientes

- Predictores, variables explicativas.

Variable Dependiente

- Target, variable objetivo.

- **Correlación:**
 - ¿Existe algún tipo de relación lineal entre las variables X e Y?
 - ¿Qué sentido y nivel de fuerza tiene la relación entre las variables X e Y?
- **Regresión:**
 - ¿Cuánto cambia Y si cambia X (o el vector de X)?
 - ¿Dado un valor de X, cuánto vale Y?





7

MODELOS LINEALES: ECUACIÓN DE LA RECTA (I)

$$Y = a + bX$$

Donde:

- **Y : Valor estimado de la variable Y para un valor de X .**
- **a : Intercepto. Valor de Y cuando $X = 0$.**
- **b : Pendiente de la recta.**
- **X : Variable independiente**



7 MODELOS LINEALES: ECUACIÓN DE LA RECTA (II)

Pendiente

$$b = r \frac{\sigma_Y}{\sigma_X}$$

Donde
:

- r : **coeficiente de correlación**
- σ_Y : **desviación estándar en Y**
- σ_X : **desviación estándar en X**

Intercepto

$$a = Y - bX$$

Donde
:

- Y : **Media de Y**
- X : **Media de X**

- El término de pendiente:

Al igual que en la correlación, el signo del término de pendiente nos sirve para medir el sentido de relación entre el predictor y el target, de manera que si es positivo el target aumenta cuando el valor de la variable aumenta y si es negativa el target se reduce cuando el valor de la variable aumenta. Además, el valor del término indica el grado de la relación (cuánto aumenta el target con un aumento unitario de la variable).


7 MODELOS LINEALES: EJEMPLO (I)

Imaginemos que tenemos que generar una aplicación capaz de estimar el nivel de colesterol LDL en sangre de un paciente a partir del peso de éste. Una opción posible es recoger conocimiento experto (médico) y programar las reglas que éste establezca en un ordenador, de manera que dado un input (peso) el programa ejecute un algoritmo (conjunto de reglas) y obtenga una estimación del colesterol LDL.

Este procedimiento, sin embargo, tiene varias carencias: (1) debemos asumir que existe un conocimiento experto completo y ser capaces de recogerlo y programarlo y (2) este conocimiento será estático o requerirá de actualización manual.

Una alternativa es utilizar un conjunto de datos etiquetados previos y utilizarlos para obtener un patrón, a partir del cuál podamos inferir, a partir del valor del peso, el nivel de colesterol LDL para ejemplos futuros no etiquetados (en los que no dispongamos del valor del colesterol).

Peso	Colesterol LDL
84	167
73	119
65	107
70	125
62	106
94	210






7

MODELOS LINEALES: EJEMPLO (II)


La recta de mejor ajuste para este problema es $y=3,3x-110$, dónde 3,3 es el pendiente de la recta (por cada aumento de 1 en X, Y aumenta 3) y 110 es el intercepto (valor de partida).



7 MODELOS LINEALES: AJUSTE DE LA RECTA

¿Cómo podemos encontrar la línea que mejor ajusta la distribución del Scatter Plot? Es decir, la línea que mejor describe la relación entre las variables X e Y .

El método de ajuste parte del racional que la mejor recta es aquella que minimiza la distancia entre los valores de la predicción y los valores



Para evitar el problema de las desviaciones positivas y negativas, miramos las desviaciones cuadráticas. El método de mínimos cuadrados se basa en la minimización del error cuadrático, y por tanto en buscar la recta cuyos valores minimizan la suma de los cuadrados del error vertical entre la predicción y el valor real. Este método de estimación se conoce como *Ordinary Least Squares* (OLS).

9 MODELOS LOGÍSTICOS: INTRODUCCIÓN

Como alternativa a los modelos de regresión lineal, para problemas de clasificación binaria se dispone de los modelos de regresión logística. En los modelos de regresión logística se utiliza la función logística (la sigmoide) para ajustar los valores del target. Todos los racionales del modelo lineal son válidos para el modelo logístico, que además no necesita que se establezca una relación lineal entre las variables independientes y la dependiente.

La función logística permite mapear los predictores a un valor continuo entre 0 y 1, que se demuestra que puede interpretarse como la probabilidad de membresía a cada una de las clases. Dicha probabilidad puede interpretarse directamente o convertirse a un valor categórico a través de la definición de un umbral de probabilidad.


A diferencia de los árboles de decisión, la regresión logística es un modelo paramétrico (con alto bias), por lo que es muy robusto frente a over- fitting (sacrificando el variance). Al ser un modelo robusto y fácilmente explicable (los coeficientes son interpretables), por lo que es muy utilizado en scoring on-line y modelos auditados.

Variables Independientes

- Predictores, variables explicativas.

Variable Dependiente

- Target, variable objetivo.





MODELOS LOGÍSTICOS: LA ECUACIÓN DE LA SIGMOIDE

Regresión lineal: $Y = a + bX$

+
=

Ecuación de la sigmoide: $p = \frac{1}{1+e^{-y}}$

$$p = \frac{1}{1 + e^{- (a+bX)}}$$

Donde:

- **Y:** Valor estimado de la variable Y para un valor de X .
- **a :** Intercepto. Valor de Y cuando $X = 0$.
- **b :** Pendiente de la recta.
- **X :** Variable independiente



8. ESTRATEGIAS DE REMUESTREO



8

ESTRATEGIAS DE REMUESTREO : EL ENGAÑO DE LA MÉTRICA

Como ya se indicó, uno de los aspectos clave en la resolución de un problema de Machine Learning es la correcta selección de la métrica de validación.

Como ejemplo, en los problemas de clasificación supervisada, hablamos de la Precisión (Accuracy) como una de las métricas más intuitivas y fáciles de entender. Como ya indicamos, esta métrica tiene una elevada dependencia de la ratio de prevalencia de la clase positiva (número de instancias de la clase positiva sb. total), y no es adecuada para casos en los que esta ratio se aleje de valores cercanos al 50%. Por este motivo, al trabajar con conjuntos de datos no balanceados, es adecuado seleccionar métricas de validación distintas al Accuracy, como el AUC o el F1.






8

ESTRATEGIAS DE REMUESTREO : ESTRATEGIAS DE REMUESTREO

Ocurre, sin embargo, que un gran número de algoritmos funciona utilizando métricas internas de precisión (como la maximización de la entropía en los árboles de decisión o el RMSE en los modelos lineales), lo que hace que en el desarrollo del modelo se premie la reducción del error sobre el reconocimiento de casos positivos, llevando a soluciones sub-óptimas en el proceso que conocemos como sub-ajuste.

Por este motivo, es importante que al trabajar con datos no balanceados utilicemos un segundo mecanismo de control consistente en rebalancear el conjunto de datos, haciendo que la relación de presencia de ambas clases sea suficiente como para evitar los problemas de subajuste.

Los dos métodos más sencillos y eficientes de remuestreo son el Oversampling (generar elementos de la clase minoritaria por copia) y el Undersampling (eliminar elementos de la clase mayoritaria). Al trabajar con Oversampling es importante tener en cuenta que la replicación de instancias puede llevar a over-fitting y que el consumo de memoria será mayor, mientras que al trabajar con Undersampling hay que tener en cuenta que puede producirse pérdida de información o quedarnos con un Dataset demasiado pequeño que no nos permita un buen ajuste. Por este motivo, es importante controlar la ratio de rebalanceo evitando dichos inconvenientes.





Muchas gracias!

