

TRABAJO DE FIN DE MÁSTER

DSMarket

De la intuición al dato

Cuatro encargos para una cadena de supermercados en transformación

Memoria del proyecto

Máster en Data Science & AI · Nuclio Digital School

Equipo del proyecto

Osvaldo Javier Hernández Vélez

Jon Mikel García Zurutuza

Jorge Espina Casado

Ronal Hernando Cuesta Chaverra

Tutor

Matías José Hermida

Defensa: 21 de mayo de 2026

Curso académico 2025-2026

Índice

1. Introducción.....	1
1.1. Cuatro encargos	1
1.2. Cómo leer esta memoria	2
2. Objetivos.....	2
2.1. Objetivo general	2
2.2. Los cuatro encargos como objetivos específicos	2
3. Metodología empleada	3
3.1. Cómo abordamos el proyecto	3
3.2. Los datos disponibles	3
3.3. Stack tecnológico y herramientas	3
4. Resultados y conclusiones	4
4.1.1. La situación que encontramos	4
4.1.2. Cómo lo abordamos.....	5
4.1.3. Lo que descubrimos	5
4.1.4. Lo que entregamos: el servicio de BI	6
4.2. Encargo 2 – Encontrar grupos accionables.....	7
4.2.1. La pregunta detrás de la pregunta.....	7
4.2.2. Cómo lo abordamos.....	7
4.2.3. Lo que estamos descubriendo.	8
4.2.4. Lo que entregamos.	10
4.3. Encargo 3 – Sustituir la intuición por un modelo	10
4.3.1. La situación que encontramos	10
4.3.2. Cómo lo abordamos.....	10
4.3.3. Prophet	11
4.3.3. Modelos Gradient Boost:	12
4.3.4. Resultados de predicción	12
4.3.5. Líneas futuras.....	14
4.4. Encargo 4 – Llevar el modelo al negocio	14
4.4.1. La situación que encontramos	14
4.4.2. La propuesta	15
4.4.3. La solución que proponemos a Operaciones	15
4.4.4. Qué cambia para DSMarket.....	16
4.5. La historia completa, en una página	17
4.5.1. Conclusión.....	17
5. Referencias	18

1. Introducción

Esta memoria es el resultado de un ejercicio de role-play. Durante el máster nos hemos puesto en la piel de Nicole, una científica de datos sénior contratada por DSMarket, una cadena de supermercados estadounidense que llega a ayudar a la transformación digital de la cadena. Nicole reporta a Paul Rogers, Director Financiero, aunque la persona que ha impulsado su contratación es Michelle Huggins, la nueva Chief Digital Officer. El análisis de los primeros meses está acotado a tres ciudades: Nueva York, Boston y Filadelfia.

A las pocas semanas de su llegada, Nicole tiene cuatro peticiones encima de la mesa, una por cada interlocutor. Esta memoria recorre las cuatro: lo que se pidió en cada caso, cómo lo abordamos, qué encontramos por el camino y qué deja todo eso a la compañía.

1.1. Cuatro encargos

Cada uno viene de una voz distinta dentro de la organización, y cada voz tiene su acento y su urgencia.

«Necesitamos entender cada detalle del negocio. Confío en ti para eso.»

— Michelle Huggins, Chief Digital Officer

«Sería ideal que pudiéramos identificar grupos de productos que se comporten de manera similar... ¿Y las tiendas? ¿Podrías hacer eso también?»

— Joelle, Marketing Manager

«DSMarket siempre ha dependido de enfoques rudimentarios para predecir las ventas. Podemos hacer un trabajo mucho mejor del que estamos haciendo ahora.»

— Paul Rogers, Director Financiero

«¿Podrías redactar una propuesta que detalle tu solución para aplicar los modelos de ventas al caso de uso de abastecimiento de tiendas?»

— Paul Rogers, Director Financiero

Los cuatro tienen algo en común. En todos ellos hay un proceso que hasta ahora dependía de la intuición o de la experiencia personal de alguien, y que la dirección quiere convertir en algo medible y repetible. Las cuatro caras del problema son distintas: conocer el negocio, segmentarlo, predecirlo y, por último, conectar la predicción con la operación diaria de las tiendas.

1.2. Cómo leer esta memoria

La memoria sigue la estructura formal que pide el programa, pero está pensada para leerse como un informe que la propia Nicole entregaría a la dirección. Cada encargo tiene su capítulo y dentro de cada capítulo se cuenta la situación de partida, el enfoque que adoptamos, los hallazgos relevantes y lo que queda entregado.

2. Objetivos

2.1. Objetivo general

Construir una primera capa analítica para DSMarket que permita ir sustituyendo, encargo a encargo, la intuición por la evidencia. La compañía ha definido un plan de transformación a cinco años; nuestro trabajo cubre la primera fase de ese plan.

Más allá del producto técnico de cada encargo, hay un objetivo cultural detrás: dejar instaladas las prácticas y que los hábitos analíticos perduren. Es un punto que nos parece importante porque, si la herramienta que entregamos solo la sabemos usar nosotros, el proyecto fracasa, aunque los modelos sean impecables.

2.2. Los cuatro encargos como objetivos específicos

Cada uno de los encargos descritos en la introducción se traduce en un objetivo concreto:

- **Encargo 1, Michelle (CDO).** Entender en detalle el estado actual del negocio en las tres ciudades, contrastar con datos las hipótesis que tiene la dirección sobre productos, ciudades y precios, y desplegar un servicio de Business Intelligence que permita a los ejecutivos consultar los KPI sin pedir un análisis ad-hoc.
- **Encargo 2, Joelle (Marketing).** Encontrar grupos de productos con comportamiento similar para Marketing y aplicar un enfoque comparable a las tiendas, de forma que las campañas se puedan diseñar y evaluar por arquetipo y no por categoría administrativa.
- **Encargo 3, Paul (CFO).** Desarrollar un nuevo enfoque de predicción de ventas con horizonte de 28 días a nivel tienda-producto, medir el error que obtiene y discutir si la práctica actual de sumar predicciones individuales para los agregados sigue siendo aceptable.
- **Encargo 4, Paul y Martin.** Redactar una propuesta funcional que conecte los modelos de predicción con el proceso semanal de abastecimiento, indicando qué extensiones del modelo hacen falta, qué requisitos de producción se deben cumplir y cómo debería ser la API que ejecutará Operaciones.

3. Metodología empleada

3.1. Cómo abordamos el proyecto

Antes de escribir código, pasamos un tiempo deliberado leyendo. Analizamos los correos de Michelle, Paul, Joelle y Martin con cuidado para identificar dos tipos de pregunta en cada uno: las que estaban planteadas explícitamente y las que no se hacían, pero tendríamos que responder igual para que las primeras no quedaran cojas. Por ejemplo, Michelle no pregunta directamente por la calidad de los datos, pero si no la verificamos, los hallazgos sobre productos en declive valdrían poco. Esa lectura previa marcó el plan de trabajo.

A partir de ahí estructuramos el proyecto siguiendo CRISP-DM, que es el método estándar de facto en la industria para proyectos de minería de datos: comprensión del negocio, comprensión y preparación de los datos, modelado, evaluación y despliegue. No lo seguimos al pie de la letra como un manual, pero sí lo usamos como mapa para no dejar fases descubiertas.

3.2. Los datos disponibles

Los datos llegaron por la vía Martin, el Technology Lead, no estaba precisamente entusiasmado con darnos acceso a los sistemas corporativos durante los primeros meses, así que volcó tres ficheros en una carpeta compartida y nos dejó trabajar con eso mientras se aprobaban los accesos formales. Los ficheros son:

- ***daily_calendar_with_events.csv***. Calendario diario con día de la semana, identificador interno y, cuando aplica, el nombre del evento (festividades, promociones especiales). Este fichero ha sido la pieza clave para enriquecer las series temporales con información de calendario, que en retail explica buena parte de la varianza.
- ***item_prices.csv***. Precio semanal por producto y tienda, en formato year-week. Detalle importante: la ausencia de un registro implica que no hubo ventas del producto esa semana, no que el precio fuera nulo. No es lo mismo y nos costó un rato darnos cuenta.
- ***item_sales.csv***. Serie diaria de unidades vendidas por combinación producto-tienda, con metadatos del producto (categoría, departamento) y de la tienda (nombre, código, región). Venía en formato ancho, con una columna por día (d_1, d_2, etc.), que fue lo primero que tocó pasar a formato largo.

Tras la limpieza, creamos una tabla a la que llamamos **df_dsMarket** que sostiene todo el proyecto.

3.3. Stack tecnológico y herramientas

Hemos optado por un stack reproducible y abierto, alineado con lo que se utiliza hoy en Data Science:

- **Python 3 con pandas y NumPy** para la manipulación de datos. Matplotlib y Seaborn para visualización exploratoria. Scikit-learn para clustering. Para los modelos de series temporales

hemos combinado statsmodels, hemos probado Prophet y finalmente hemos aplicado LightGBM, XGboost.

- **Jupyter Notebook y Visual Studio Code** como entornos de desarrollo principal.
- **Power BI Desktop** para el servicio de BI del primer encargo. La elección la condiciona Michelle al final del primer correo: pidió que usáramos la solución para dashboards con la que se sintiera más cómoda la capa ejecutiva.
- **Slack** como canal de comunicación con los tutores y entre los miembros del equipo, siguiendo lo que indicaba la guía del proyecto.
- **Herramientas de IA generativa** ([Chat GPT](#) de OpenAI, [Gemini](#) de Google y [Claude](#) de Anthropic) han sido empleadas para la creación de código y depuración de errores. Todo el código generado ha sido revisado, testeado y modificado por los autores del presente trabajo.

4. Resultados y conclusiones

Los resultados se presentan encargo a encargo. Cada uno tiene su propia historia, pero el patrón es similar: en todos hay un punto de partida insatisfactorio, un trabajo de exploración, un entregable concreto y una conclusión sobre qué cambia para el negocio a partir de aquí.

4.1. Encargo 1 – Comprender el estado del negocio

Solicitado por Michelle Huggins, Chief Digital Officer.

«Hasta ahora solo he podido ir echando un ojo a las tendencias de ventas globales que me han ido pasando, pero me gustaría evaluar desde ya cada ángulo de nuestra actividad. Mi intuición me dice que probablemente tenemos productos que ya no son tan populares, y es probable que los productos más populares varíen entre ciudades, o incluso entre tiendas (que también pueden variar en precios).»

— Michelle Huggins, CDO

4.1.1. La situación que encontramos

Lo primero que descubrimos fue que la dirección sabía mucho de su empresa, pero no podía consultarlo cuando lo necesitaba. Las tendencias agregadas estaban claras: el ingreso anual, el crecimiento global, el ranking de tiendas grandes. En cambio, cuando alguien preguntaba en una reunión por algo más concreto —qué productos estaban perdiendo tracción, si Boston se comportaba como Nueva York, si los precios eran homogéneos entre tiendas— alguien tenía que ir a montar un

Excel a mano. Ese ciclo era el primer problema a resolver, y el más urgente, porque lastraba todas las demás iniciativas.

Michelle nos planteó tres hipótesis de partida en su correo: que había productos que ya no son tan populares, que los productos populares varían entre ciudades y entre tiendas, y que los precios del mismo artículo pueden ser distintos en distintas tiendas. Tres intuiciones, sobre las que había que poner datos.

4.1.2. Cómo lo abordamos

La primera semana fue un trabajo poco vistoso pero inevitable: revisar la calidad de los datos. Comprobamos cobertura temporal por tienda y producto, identificamos huecos en las series, validamos rangos numéricos y resolvimos el formato ancho de las ventas diarias pasándolo a formato largo. El detalle del precio nulo, que haya ausencia de registro, implica falta de ventas, no que el precio sea cero. Esto, por ejemplo, nos hizo perder unas horas hasta que cuadró todo.

Una vez los datos estuvieron limpios, construimos una tabla enriquecida. `datafact_sales_final`, que cruza ventas, precios, calendario y dimensiones de tienda y producto. Sobre esa tabla definimos cuatro medidas calculadas que actúan como columna vertebral del dashboard:

- **Ingresos:** producto de unidades vendidas por precio de venta. Es la medida base.
- **Precio_Medio_Venta:** precio medio ponderado por unidades vendidas. Sirve para detectar variaciones reales (las que ven los clientes) y no las de catálogo.
- **Crecimiento_Anual_%:** variación porcentual interanual de los ingresos para el mismo período del año anterior.
- **Ventas_Sin_Cero:** unidades vendidas excluyendo registros con valor cero. Útil cuando se compara la varianza entre tiendas y los ceros distorsionan.

4.1.3. Lo que descubrimos

Las tres intuiciones de Michelle se confirmaron, lo que en sí mismo ya es un hallazgo: la dirección no iba desencaminada. Pero había matices que valía la pena documentar.

Las diferencias entre ciudades son claras y, dentro de cada ciudad, hay tiendas con perfiles muy distintos. El peso relativo de Nueva York, Boston y Filadelfia en el ingreso total no es homogéneo, y eso ya lo sospechábamos. Lo que sí nos sorprendió un poco es la heterogeneidad dentro de una misma ciudad: hay tiendas que se parecen más a una tienda de otra ciudad que a su vecina del mismo barrio. Para una decisión de marketing, esto importa: una campaña diseñada al nivel de ciudad puede no funcionar para todas las tiendas de esa ciudad.

La concentración del ingreso en pocos productos es pronunciada. La distribución por producto tiene una cola larguísima, con un grupo reducido de referencias que concentra una parte sustancial del revenue y una mayoría que apenas mueve volumen. Este hallazgo lo retomamos en el segundo encargo (la segmentación) y, sobre todo, en el cuarto (la priorización del abastecimiento): no tiene

sentido invertir el mismo esfuerzo de planificación en un producto que vende cuatro unidades a la semana que en uno que vende cuatrocientas.

Respecto a los ingresos, creemos que centrarnos en los más populares sería un error, ya que estos representan únicamente el 5% de los ingresos globales.

Sobre los precios, el mismo producto sí puede tener precios distintos en tiendas distintas. La variación, combinada con las diferencias de volumen entre las mismas tiendas, sugiere una sensibilidad al precio diferenciada por establecimiento. Es un input para un futuro caso de uso de optimización de precios que está en la hoja de ruta de la compañía, pero queda fuera del alcance de este proyecto.

Por último, los eventos del calendario tienen un impacto medible y consistente en el tiempo sobre las ventas. Esto era de esperar, pero conviene tenerlo documentado, porque es la base sobre la que se construyen los modelos de predicción del Encargo 3: el calendario es una variable explicativa que no se puede ignorar.

4.1.4. Lo que entregamos: el servicio de BI

Para que la dirección dejara de depender de Excels ad-hoc desarrollamos un informe en Power BI con diez páginas, cada una orientada a una pregunta de negocio concreta:

Página	Pregunta de negocio que responde
Portada	Identificación del informe, contexto y navegación
Resumen	¿Cuál es el estado global del negocio? Ingresos, precio medio, crecimiento anual, top de departamentos y evolución mensual.
Tiendas	¿Qué tiendas y regiones aportan más ingresos? Treemap por tienda, KPI de ingreso medio, tendencia de las cuatro tiendas top y evolución por región.
Eventos	¿Qué impacto tienen los eventos del calendario? Ranking por ingresos y evolución temporal.
Productos	¿Qué productos venden más y cuáles menos? Top 10 y Bottom 10 por ingresos y por unidades, con filtros por categoría, región y tienda.
Precios	¿Existen diferencias de precio del mismo producto entre tiendas? Tabla pivote producto × tienda con el precio.
Ventas	¿Cómo varían las ventas del mismo producto entre tiendas? Tabla pivote producto × tienda con unidades, excluyendo ceros.
Clusters	Página de comparativa entre dimensiones, en construcción para iteraciones posteriores.
Predicciones	Página en la que presentamos la predicción de ventas a 4 semanas
Implementación	Describimos la posible implementación del modelo mediante un diagrama

El dashboard sustituye al circuito de Excel ad-hoc que existía hasta ahora. La capa ejecutiva ya no necesita pedir un análisis cada vez que tiene una pregunta: entra al informe y la resuelve. Y, lo que para nosotros es más importante de cara al futuro, las preguntas nuevas que vayan surgiendo se incorporan al mismo informe en lugar de generar nuevos archivos Excel sueltos que se pierden en correos.

4.2. Encargo 2 – Encontrar grupos accionables

Solicitado por Joelle, Marketing Manager, con copia a Paul y Michelle.

«Hablando con Michelle, hemos pensado que sería ideal que pudiéramos identificar grupos de productos que se comporten de manera similar... ¿Cuántos grupos crees que deberíamos considerar? ¿5? ¿10? ¿20? Además, ¿crees que podríamos encontrar un enfoque «similar» para identificar cómo de similares son las tiendas entre sí?»

— Joelle, Marketing Manager

4.2.1. La pregunta detrás de la pregunta

Joelle nos planteó la petición con tres alternativas concretas. La tentación inicial fue responder a la pregunta literal y devolverle un número. Pero antes de hacerlo nos paramos a pensar qué problema estaba intentando resolver. Joelle no necesita grupos; necesita poder diseñar campañas diferenciadas y poder evaluar después si esas campañas han funcionado en cada tipo de producto. La pregunta real, por lo tanto, no es cuántos grupos sino qué tipo de agrupación es accionable para ella.

Esa reformulación tiene una consecuencia metodológica importante. El número final de clusters no se elige a dedo, se deduce. Y se deduce combinando criterios técnicos con un criterio de interpretabilidad, porque un cluster que el equipo de Marketing no sabe describir y nombrar no sirve, por mucha silueta que tenga el modelo.

4.2.2. Cómo lo abordamos

Para abordar la petición de Joelle, se optó por un enfoque de clustering no supervisado, técnica que permite identificar grupos naturales en los datos sin necesidad de etiquetas previas. A diferencia de un enfoque supervisado, el clustering deja que la propia estructura del catálogo determine cuántos comportamientos distintos existen y cuáles son, respondiendo así directamente a la pregunta planteada: ¿cuántos grupos deberíamos considerar?

El algoritmo seleccionado fue **KMeans**, por su eficiencia computacional con datasets de este tamaño, su interpretabilidad y su adecuación a datos numéricos continuos. Todo el proceso se implementó con un **pipeline de sklearn**, encadenando los transformadores de feature engineering, el escalado y el

modelo de clustering en un único objeto reproducible. Esta decisión de diseño garantiza que el mismo pipeline pueda aplicarse a nuevos datos sin riesgo de fugas de información entre pasos, y facilita su eventual despliegue en producción.

El punto de partida del modelo no son las columnas brutas del dataset sino **7 dimensiones de comportamiento** construidas expresamente para capturar cómo se vende cada producto a lo largo de su vida activa. Este proceso de feature engineering es la parte más crítica del proyecto — un modelo de clustering es tan bueno como las features que lo alimentan.

El primer paso fue definir la **vida activa** de cada producto, filtrando desde su primera venta real para evitar que los días de cero ventas previos al lanzamiento distorsionen las métricas de frecuencia y volatilidad. A partir de ahí, se agrega el dataset — que tiene una fila por producto, tienda y día — a un único vector de características por producto.

Las 7 dimensiones finales cubren cuatro dimensiones de comportamiento complementarias. El **volumen total** y el **precio medio** capturan la escala y el posicionamiento del producto en el catálogo. La **frecuencia de venta** y la **volatilidad** miden la regularidad con la que el producto genera demanda — un Pilar de la Tienda tiene frecuencia alta y volatilidad baja, mientras que un Long Tail tiene el patrón inverso. La **proporción de ventas en oferta** y la **profundidad media del descuento** capturan el comportamiento promocional, y son deliberadamente dos variables distintas porque miden cosas distintas — un producto puede tener descuentos frecuentes pero superficiales, o poco frecuentes pero muy agresivos, como es el caso de las Liquidaciones Puntuales. Finalmente, la **proporción de ventas en primavera-verano** captura la estacionalidad de cada producto en una única variable continua.

Varias decisiones técnicas merecen mención específica. Se calculó el precio de referencia de cada producto mediante una ventana deslizante de 28 días, evitando el **lookahead bias** — es decir, asegurando que el modelo no usa información del futuro para detectar si el precio de hoy es un descuento. Las variables con colas largas — volumen, precio y volatilidad — se transformaron a escala logarítmica para comprimir la asimetría de su distribución y evitar que productos extremos dominen el clustering.

Se exploraron también features adicionales que finalmente se descartaron: variables de eventos (SuperBowl, Pascua, Ramadán), días de pago y datos externos de inflación por categoría del BLS. Todas ellas empeoran el Silhouette Score al incluirlas, lo que indica que no aportan señal discriminante entre productos — los eventos y la inflación afectan al catálogo de forma relativamente homogénea y no ayudan a diferenciar comportamientos individuales.

4.2.3. Lo que estamos descubriendo.


El análisis revela que el catálogo de DSMarket no es homogéneo — detrás de los 3.049 productos existen **6 patrones de comportamiento claramente diferenciados** que responden a lógicas

comerciales distintas y que, gestionados de forma individual, abrirán oportunidades de optimización significativas.

El hallazgo más relevante es la identificación de los **Pilares de la Tienda**, que con más de 1.000 referencias concentran el mayor volumen de ventas y la mayor frecuencia de compra del catálogo a los precios más bajos. Son el motor silencioso del negocio y los primeros candidatos a cualquier política de garantía de stock. En el extremo opuesto, el cluster **Long Tail / Especialidades** agrupa casi 950 productos con el precio medio más alto, baja rotación y ventas erráticas — un segmento que merece una revisión de rentabilidad antes de seguir manteniendo en catálogo.

Otro descubrimiento relevante es la distinción entre los dos clusters de descuento. Los **Promocionales** son productos cuyas ventas están directamente correlacionadas con la activación de ofertas — responden al descuento. Las **Liquidaciones Puntuales**, en cambio, apenas se ponen en oferta, pero cuando lo hacen el descuento medio supera el 50% — una señal de alerta que puede indicar liquidaciones no planificadas o una estrategia de precios reactiva en lugar de estratégica.

En la siguiente imagen se puede ver el perfil individual de los 6 segmentos de productos de DSMarket sobre las 7 dimensiones de comportamiento. Cada radar representa las características medias del cluster respecto al resto del catálogo.



Joelle también nos planteó la posibilidad de aplicar un enfoque similar para identificar grupos de tiendas. Esta línea de análisis se descartó por una razón estadística fundamental: DSMarket cuenta únicamente con **10 tiendas**, un número insuficiente para obtener clusters significativos y estadísticamente robustos. Con tan pocas observaciones, cualquier agrupación obtenida sería arbitraria. La segmentación de tiendas podría revisarse en el futuro si DSMarket expande su red a un número de establecimientos que lo justifique.

4.2.4. Lo que entregamos.

El entregable de este encargo se compone de dos piezas. El código del pipeline de clustering, en notebook reproducible y documentado, con todos los transformadores custom explicados y las decisiones metodológicas justificadas. Del notebook, se genera un dataset en formato .csv (**datos_productos_powerbi.csv**) con cada producto agrupado con las métricas que se han calculado y con el correspondiente **cluster** al que pertenece, con el fin de incorporarlo al dashboard de Power BI. Se desarrolló una página dedicada en el dashboard de Power BI donde Joelle y su equipo pueden explorar los segmentos de forma interactiva — filtrando por región, categoría y tienda — sin necesidad de tocar el código ni los datos.

4.3. Encargo 3 – Sustituir la intuición por un modelo

Solicitado por Paul Rogers, Director Financiero, con apoyo técnico de Martin para el formato de evaluación.

«DSMarket siempre ha dependido de enfoques rudimentarios para predecir las ventas de productos... la razón principal detrás de tu incorporación temprana es el desarrollo de un nuevo enfoque para la predicción. Hasta ahora, siempre hemos ido prediciendo las ventas a nivel de tienda-producto, y para obtener ventas agregadas por departamento/tienda/ciudad sumamos las predicciones independientes. ¿Seguiría siendo un enfoque válido?»

— Paul Rogers, CFO

4.3.1. La situación que encontramos

La predicción de ventas en DSMarket era hasta nuestra llegada un proceso manual basado en la experiencia del equipo financiero y comercial. Cada mes, a veces cada trimestre, alguien con conocimiento del negocio estimaba un número y ese número se utilizaba para presupuestos, decisiones de compra y planificación de tiendas. El método tenía dos problemas estructurales: el error era considerable y, lo que es peor, no estaba cuantificado. Nadie sabía exactamente lo equivocada que estaba la predicción hasta que ya era tarde para reaccionar. Y el conocimiento estaba en personas, no en procesos: si alguien se iba, el método se iba con él.

Paul nos pidió predicciones a nivel tienda-producto con horizonte de 28 días, alineado con los ciclos de planificación de Operaciones.

4.3.2. Cómo lo abordamos

Con el objetivo de encontrar el modelo que mejor se adapte a nuestro dataset, se han entrenado el modelo descomposicional con efecto calendario Prophet y los modelos Gradient Boost: XGBoost y


LightGBM. La validación se hace mediante backtesting de ventana deslizante, que es el método correcto en datos temporales: no vale partir aleatoriamente en train y test porque eso provocaría fugas de información del futuro al pasado. Las métricas son RMSE, MAE y WMAPE, este último pondera el error por el volumen del producto y por eso se comporta mejor que otras alternativas en retail, donde los volúmenes entre productos varían en órdenes de magnitud.

4.3.3. Prophet

Al entrenar el modelo Prophet nos encontramos con problemas, realizando un approach de predicción diaria (con predicción semanal había pocos datos).

Muchos días con cero ventas, lo que hace perder eficacia a este tipo de modelo que predice mejor cantidades más sostenidas en el tiempo y no con tanta variabilidad. Con objetivo de reducir los días con cero ventas, se decide realizar predicciones de cada item, pero considerando todas las tiendas a la vez.

Los resultados de este modelo dependen en gran parte de la variabilidad del producto. Si es un producto más estable la predicción global es buena, pero tiene dificultades con productos de mucho cambio durante los días y además no podemos, por lo menos por el momento, implementar una predicción semanal por falta de datos.




Como se puede observar en la ilustración anterior, el modelo predice correctamente la tendencia que tienen las ventas cada semana. Sin embargo, las grandes variaciones en la demanda son su punto débil y dada lo importante que puede resultar en nuestro negocio que se cubran las demandas para maximizar ventas, vamos a decidir probar los modelos de Gradient Boost.

4.3.3. Modelos Gradient Boost:

Para llevar a cabo la predicción semanal se decide emplear los modelos XGBoost y LightGBM. Una vez tuneados, se emplearán ambas predicciones para hacer una predicción conjunta con un peso para cada modelo que se calculará para obtener los mejores resultados.

La predicción se realizará de forma conjunta ya que LightGBM puede predecir de mejor manera grandes variaciones de demanda y XGBoost es buen modelo para productos que sean más estables.

A continuación, se muestran las feature importance de cada modelo. Como se puede observar, XGBoost se apoya en variables de lag y rolling (media de las semanas anteriores) y LightGBM en el día del año, lags (dato de semana(s) anterior(es)) y precio.




4.3.4. Resultados de predicción

Los resultados son los esperados, cuanto más estable son las ventas, las predicciones son mejores. Tiendas, productos, regiones con más variabilidad son más complicadas de predecir, pero como se puede observar en la siguiente ilustración, el modelo es capaz de predecir correctamente tendencias como las descendentes en los departamentos Accessories 1 y 2 y Home_&_Garden_2, o las ascendentes en Home_&_Garden_1 y Supermarket_1.

Cabe destacar que estos resultados tienen una fiabilidad ligeramente superior al 60% (calculado con WMAPE) y se muestran en sumatorio de todos los productos.

Aggregated predictions by department — last 13 weeks



4.3.5. Líneas futuras

El entregable de este encargo se compone de cuatro piezas. La adaptación de las tablas de datos a formato de datos semanales, las funciones de preparación y entrenamiento de los modelos XGBoost y LightGBM, gráficos de feature importance, errores y comparativas de cada modelo, y por último, las predicciones.

El notebook cumple con las peticiones y puede alimentar el dashboard entregado en vistas a hacer predicciones con más datos que pudieran llegar. Además de lo entregado, las líneas futuras del trabajo de predicción serían:

- Adición de información al modelo: más regiones, si hay stock de cada item-tienda o no, etc.
- Revisión de eventos de calendario que puedan formar parte de las semanas a predecir.
- Adición de los clusters (siendo realizados con los datos de entrenamiento).
- Una vez mejorado el modelo y contrastada su eficacia, podría resultar interesante añadir una diapositiva de resumen de predicciones empleando la columna 'trend_label' para mostrar las tendencias, tanto en ventas como en beneficios, así como productos top y bottom por la predicción.
- De cara a la producción, creación de la pipeline con scikit learn para facilitar tuneados y resolución de errores o grandes desviaciones.

4.4. Encargo 4 – Llevar el modelo al negocio

Solicitado por Paul Rogers, Director Financiero, con apoyo de Martin para el despliegue técnico.

«El abastecimiento de stock a tiendas se lleva a cabo de manera semanal, al principio de cada semana (aunque si es necesario, el stock de algunos productos se puede reponer diariamente). Probablemente ya estés visualizando la importancia de las predicciones de ventas para eso. Minimizar el stock remanente es el sueño de todo retailer, pero ese sueño es aún más fuerte para los artículos de supermercado.»

— Paul Rogers, CFO

4.4.1. La situación que encontramos

El abastecimiento de tiendas era, hasta el despliegue de esta solución, un proceso manual y muy dependiente del juicio del responsable de cada tienda. Cada lunes, los gerentes revisaban su stock, miraban las ventas de la semana anterior, hacían una previsión mental y pasaban sus pedidos. Funcionaba, en el sentido de que las tiendas estaban abastecidas, pero generaba dos costes crónicos. Por un lado, el stock remanente, que en supermercado tiene un coste especialmente alto porque muchos productos son perecederos. Por otro las roturas de stock, que cuestan ventas y, peor, satisfacción del cliente.

4.4.2. La propuesta


La idea es aplicar el modelo de predicción del Encargo 3 al proceso semanal de reposición, con cuatro componentes diferenciados:

- **Predicción.** Cada domingo por la noche el modelo genera una predicción de demanda para los siete días siguientes a nivel tienda-producto. La frecuencia base es semanal, con la posibilidad de ejecuciones diarias para productos críticos (alta rotación, alto margen) o tras eventos imprevistos.
- **Sobre-stock dependiente de la incertidumbre.** Sobre la predicción puntual añadimos un colchón calculado a partir de los intervalos de predicción del propio modelo y del coste relativo de rotura frente al coste de stock remanente. No es un porcentaje fijo: es una función del producto y de la tienda. Un producto perecedero con poca rotación no se sobreaprovisiona como un producto seco de alta rotación.
- **Reglas de negocio.** Sobre la propuesta del modelo se aplican restricciones operativas que el modelo por sí solo no conoce: mínimos de pedido del proveedor, capacidad de la tienda, lead time logístico. Estas reglas las conocen los responsables de tienda y se documentan para que el sistema las incorpore.
- **Punto de control humano.** En las primeras fases de implantación, la predicción se trata como propuesta, es decir, no se ejecuta automáticamente. El responsable de cada tienda la revisa y puede modificarla, registrando el motivo. Estas modificaciones alimentan la mejora continua del modelo: si un gerente cambia sistemáticamente la propuesta para un producto concreto, hay algo que el modelo no está capturando.

4.4.3. La solución que proponemos a Operaciones

Martin nos pidió desplegar una API para que Operaciones pueda consumir las predicciones. Por el momento, la solución planteada consiste en la utilización del dashboard que hemos presentado por parte de las personas de diferentes departamentos para que puedan acudir tanto a la información histórica como a las predicciones realizadas por el modelo. De esta forma, se simplifica la implementación y si en el futuro se requiriese una API u otra solución se puede buscar teniendo de base el dashboard.

El flujo de datos sería el siguiente:



Las tareas de input de datos y predicción serían automatizadas mediante el programa AirFlow. Con la entrada de datos nuevos, se entrenaría el modelo para realizar las predicciones de las siguientes 4 semanas. Los datos podrían ser abastecidos de forma semanal, de forma que se entrene (si es necesario) y se realicen predicciones con los datos más actuales posibles. Estas predicciones serían exportables para ver en el mencionado dashboard.

Con objetivo de revisar el desvío se usaría la aplicación Evidently, que permite alertar si el desvío de la predicción del modelo respecto a los datos reales es mayor que un valor fijado por el Data Scientist. Como nos ha indicado Joseph Gallart en la presentación, si se estima oportuno, se podría entrenar el modelo de forma semanal previo a realizar las predicciones. De esta forma el modelo estaría entrenado con los datos más recientes en todo momento.

4.4.4. Qué cambia para DSMarket

El abastecimiento deja de ser un juicio individual sin trazabilidad y pasa a ser una propuesta cuantitativa con margen de ajuste humano. Esto importa por dos motivos. El primero es operativo: si

funciona, se reducen el stock remanente y las roturas, que son los dos costes crónicos del retail de supermercado. El segundo es organizativo: el conocimiento que antes vivía en la cabeza de cada gerente queda documentado y es auditable. Cuando un gerente se va, su conocimiento no se va con él porque sus decisiones, las que tomó modificando la propuesta del modelo y los motivos, han quedado registradas.

4.5. La historia completa, en una página

La transformación que dejan en marcha estos cuatro encargos puede resumirse en cuatro pares de antes y después:

Frente	Antes	Después
Conocimiento del negocio	Tendencias globales conocidas; preguntas concretas resueltas con Excels ad-hoc.	Servicio de BI con 8 páginas que la dirección consulta de forma autónoma.
Segmentación	Categorías heredadas del ERP, sin criterios de comportamiento.	Arquetipos de producto y tienda nombrables y accionables para Marketing.
Predicción	Estimaciones manuales con error no cuantificado.	Modelo a 28 días con error medido (WMAPE) y proceso de reentrenamiento definido.
Abastecimiento	Decisión individual de cada gerente, sin trazabilidad ni mejora continua.	Propuesta cuantitativa revisable, con safety stock dependiente de la incertidumbre y API definida.

4.5.1. Conclusión

Lo que separaba a DSMarket de competidores más maduros no era la falta de datos. Datos hay, lo que faltaba era la disciplina de hacer mejores preguntas y los procesos para responderlas de forma sistemática. Estos cuatro encargos no resuelven todos los problemas de la cadena, pero dejan instalada esa disciplina en cuatro frentes críticos.

A partir de aquí, el equipo de Data Science que se incorporará a partir del segundo año tiene una base sobre la que seguir construyendo: un dashboard que crece con cada nueva pregunta de la dirección, una segmentación que evoluciona con cada campaña, un modelo de predicción cuyo error se mide y se mejora, y una API en proceso de despliegue que conecta el modelo con la operativa diaria. Hay margen para mejorarlo todo, naturalmente, pero el punto de partida ha cambiado.

La intuición de Michelle al fichar tan pronto un perfil de ciencia de datos se ha demostrado acertada. El plan a cinco años de la compañía gana, con este primer hito, una primera demostración tangible de su viabilidad. Que es, en el fondo, lo que ella nos había pedido al recibirnos en su primer correo.

5. Referencias

Las referencias se presentan siguiendo la normativa APA (7.ª edición), tal como exige la guía del proyecto final.

Microsoft. (2024). Power BI documentation. Microsoft Learn. <https://learn.microsoft.com/power-bi/>

Prophet Documentation. Saturating Forecasts:

https://facebook.github.io/prophet/docs/saturating_forecasts.html#forecasting-growth

Nuclio Digital School. (2026). Guía del Proyecto Final. Máster en Data Science & AI. Documento interno del programa.

Nuclio Digital School. (2026). Enunciado del Proyecto Final – DSMarket. Documento interno del programa.

Herramientas de IA generativa ([Chat GPT](#) de OpenAI, [Gemini](#) de Google y [Claude](#) de Anthropic) han sido empleadas para la creación de código y depuración de errores. Todo el código generado ha sido revisado, testeado y modificado por los autores del presente trabajo.